

הבעיה: כותרת העמוד אף פעם לא מגיעה למודל

RAG בעברית על כל-זכות · שלב האחזור בלבד · 24,487 פסקאות מתוך 7,007 עמודים

1. תצפית: קראתי את הכשלים

2. השערה: אחים נבדלים רק בכותרת

3. בדיקה בקוד: מוטמע רק content

4. אימות במספרים

עמוד אחד בנתונים: שורה לכל פסקה

הוצאת דרכון זמני

הכותרת: נשמרת, לא מוטמעת

פסקה 1: פתיח, דרכון לשנה בהליך מהיר

פסקה 2: אוכלוסיית יעד ותנאים מקדימים

פסקה 3: הליך ההנפקה בלשכות

פסקה 4: הוצאה ב-48 השעות שלפני הטיסה

פסקה 5: גורמים מסייעים (בלוק שחוזר באלפי עמודים)

בקובץ ההגדרות השדה המוטמע הוא content בלבד. 64% מהפסקאות כבר פותחות בכותרת הסעיף, כך שהסעיף בפנים. מה שחסר הוא כותרת העמוד.

תצפית: שאלה מסט הבדיקה

"דרכון דחוף"

1 הוצאת דרכון ביומטרי

2 הוצאת דרכון זמני ← הנכון

הגוף של שני העמודים כמעט זהה. ההבדל, "זמני" מול "ביומטרי", נמצא רק בכותרת.

דוגמה נוספת: "הנחה בארנונה לנכים" מול "לנכי עבודה".
דמיון בין הפסקאות הפותחות: 0.905.

המצב ההתחלתי, 296 שאלות

58%

בין 3 העמודים שנשלחים ל-GPT

37%


העמוד הנכון ראשון

מתוך 187 כשלים, 63 במקום 2-3, ברובם מאחורי עמוד אח. זה הדפוס מהתצפית.

71 כשלים נוספים הם שאלות שלא מזהות עמוד בכוחות עצמן. זו התקרה.

הפתרון: הכותרת נכנסת לטקסט שמוטמע

מפתח אחד בקובץ ההגדרות · המודל לא אומן מחדש · החיפוש, ה-API והממשק לא השתנו



איך נמדד, ולמה אפשר לסמוך


שלושה סטים. **Webiks**: סט האימות של קוד האימון שלהם. **נקי**: 150 עמודים שאין עליהם שאלה בקובץ, ושאלה לכל עמוד שנכתבה כשהכותרת מוסתרת מהכותב. **ציבורי**: 300 השאלות שפרסם מתחרה. המעריך שלי זהה למעריך של Webiks עד 4 ספרות.

ברמת השאלה

114 Webiks: השתפרו, 47 נפגעו, ושלושת הראשונים עלו מ-58% ל-65%. **נקי**: 38 מול 19. על הסט הציבורי הפרש בתוך הרעש: הכותרת עוזרת כשהשאלה מזכירה אוכלוסייה או תת-מקרה.


נבדק וכובה: וקטור כותרת נפרד במשקל 0.3

על סט Webiks נתן 53%, אבל בשני הסטים הנקיים החזיר את הרווח. הוא כבוי ונשאר בקוד כאופציה.



שלב שני אופציונלי, כבוי כברירת מחדל, ואיך הכול משתלב

מודל שפה מסדר מחדש את העמודים המועמדים לפי הכותרות שלהם · כל ספק דרך LLM factory · מדליקים בשורה אחת



נבדק ונפסל, כל אחד מול אותה מערכת בלעדיו

ניסוי	מקום 1 / 3 ראשונים
קטעים של 256 טוקנים + כותרת	-5.8 / +2.7
הקשר שנכתב ב-LLM לכל פסקה	-3.7 / -0.6
ניסוח השאלה מחדש / 4 HyDE ניסוחים	+2.4 / +3.8
סינון טקסט גנרי / 500 מועמדים	±1.5 / 0

ניסוח מחדש: רוח קטן עם הרבה שינויים לשני הכיוונים, ו-LLM בתוך החיפוש.

אינטגרציה

60 בדיקות עוברות, מתוכן 19 חדשות. החזרה למקור היא מחיקת מפתח ובנייה מחדש של האינדקס. נמצא ותוקן בדרך: הסקריפט המהיר לבניית האינדקס התעלם מקובץ ההגדרות.

LLM factory: כל מודל שרוצים

Anthropic

vLLM

Ollama

Azure

OpenAI

+ מודל משלכם

Gemini

ממשק אחד: הודעות נכנסות, טקסט יוצא. מודל חדש הוא מחלקה קטנה שנרשמת בשם.

כבוי כברירת מחדל. להדלקה, ב-app/.env: ☐

```
TITLE_RERANK_ENABLED=true
TITLE_RERANK_PROVIDER=openai
TITLE_RERANK_MODEL=gpt-4o-mini
```

בכל תקלה הוא חוזר לסדר הרגיל. מחיר: כ-0.8 שנייה לשאלה ומפתח ל-LLM. במצב mock אין לו השפעה, ולכן הוא כבוי.