

כותרת העמוד שמנוע האחזור מעולם לא ראה

RAG בעברית על כל-זכות · שלב האחזור בלבד · 24,487 פסקאות, 7,007 עמודים

1 מנוע האחזור מטמיע את גוף הפסקה בלבד.
כותרת העמוד שמורה לידו, אך לעולם אינה מגיעה למודל.

2 63 מתוך 187 ההחמצות הן במקום 2-3, רובן עמודים
אחים.
הנחה בארגונוה לנכים מול לנכי עבודה · דרכון זמני מול ביומטרי · עמוד
מול התאום שלו מתקופת המלחמה

3 64% מהפסקאות כבר נפתחות בכותרת הסעיף שלהן.
כלומר הסעיף כבר נמצא בווקטור; העמוד הוא החלק החסר.

42%

מהשאלות שולחות ל-LLM שלושה עמודים
שהעמוד הנכון אינו ביניהם (מצב קיים:
 $\text{hit}@3 = 0.58$; $\text{hit}@1 = 0.37$)

שני מפתחות קונפיגורציה מכניסים את כותרת העמוד לווקטור

1 למדוד קודם

מערכת מדידה על וקטורים שמורים, זהה למעריך של Webiks
עד 4 ספרות; 3 שניות לכל וריאנט.

2 לקרוא את השגיאות

בלבולים בין עמודים אחים ← הכותרת היא המקום שבו יושב
ההבדל.

3 לנבא, ואז לבדוק

נכתב לפני ההרצה; צדק בחצי (גם החמצות עמוקות זזו). נשמר
כפי שנכתב.

4 לבחור משקל ביושר

נסרק על חצי מהשאלות ודווח על החצי השני, בשני הכיוונים;
רמה יציבה ב-0.2–0.4.

5 לדחות על סמך ראיות

חלוקה לקטעים, הקשר שנכתב ב-LLM, סינון טקסט גנרי, מאגר
מועמדים רחב יותר: הכול נמדד, דבר לא הוכנס.

1

embed_context_fields: ["title"] 1

הטקסט שמוטמע בזמן האינדוקס הופך ל: כותרת העמוד,
מעבר שורה, ואז הפסקה.

2

3

4

5

embed_title_weight: 0.3 2

הכותרת מוטמעת בנפרד ומשולבת לתוך הווקטור השמור:

$\text{normalise}(0.3 \cdot \text{unit}(\text{title}) + 0.7 \cdot \text{unit}(\text{text}))$

הקוסינוס ליניארי בשאלתה, ולכן וקטור שמור אחד שווה ל:

$0.3 \cdot \cos(q, \text{title}) + 0.7 \cdot \cos(q, \text{text})$

אותו מודל, אותו מבנה אינדקס, אותו API חיפוש.

מקום 1: מ-37% ל-53% · שלושת הראשונים ל-LLM: מ-58% ל-71%

ברמת השאלה

138 השתפרו · 35 נפגעו · 123 ללא שינוי. רוב הנסיגות הן תזוזה של מקום אחד בין עמודים אחרים.

נבדק, לא הוכנס

- קטעים של 256 טוקנים: גרוע לבד; עם הכותרת מחליף מקום 1 בשלושת הראשונים
- הקשר שנכתב ב-LLM לכל פסקה (\$3.34): כל המדדים ירדו
- סינון טקסט גנרי, מאגר מועמדים רחב יותר: ללא השפעה

הצעד הבא

- אחזור קטן-לגדול (התאמה על קטעים, החזרת הפסקה)
- סט בדיקה נקי שנכתב בידי אדם · reranker כשלב שני נמדד

(% מאגר מלא, (seed 42) שאלות סט האימות של קוד האימון 296

