

איתור הבעיה: תצפית, השערה, בדיקה בקוד, אימות במספרים

1. תצפית, מניתוח הכשלים של המערכת המקורית

שאלה מסט הבדיקה: "דרכון דחוף". העמוד הנכון: הוצאת דרכון זמני.

הוחזר: 1. הוצאת דרכון ביומטרי 2. הוצאת דרכון זמני

הדפוס חזר: הנושא נכון, העמוד שגוי, והשגוי הוא "אח" של הנכון (זוג עם ילדים / ללא ילדים, השלמת הכנסה לזיקנה / לשאירים).

2. השערה

גוף הטקסט של עמודים אחים כמעט זהה; מה שמבדיל ביניהם הוא כותרת העמוד. אם המודל לא רואה את הכותרת, אין לו על מה להבדיל.

3. בדיקה בקוד

בקובץ ההגדרות של ה-Demo השדה שמוטמע (field_to_embed) הוא content בלבד. הכותרת נשמרת באינדקס ליד הפסקה ולא נכנסת למודל.

4. אימות במספרים (296 שאלות סט האימות של קוד האימון, 24,487 פסקאות)

המערכת המקורית: מקום ראשון 36.8%, בשלושת הראשונים 58.1%. ה-Demo שולח ל-LLM שלושה עמודים, כך שב-42% מהשאלות הנכון אינו ביניהם.

187 כשלים לפי מיקום העמוד הנכון:

- מקום 2-3: 63, ברובם עמוד אח ראשון. זה הדפוס מהתצפית.
- מקום 4-10: 53, מעורב; עמודי "מדריך" כלליים גוברים.
- מעל 10: 71, שאלות שלא מזהות עמוד בכוחות עצמן. התקרה.

64% מהפסקאות כבר נפתחות בכותרת הסעיף, כך שהסעיף בווקטור. החלק היחיד שחסר הוא כותרת העמוד.

הפתרון: כותרת העמוד נכנסת למה שמוטמע. נמדד על שלושה סטים

מה השתנה

מפתח אחד בקובץ ההגדרות (embed_context_fields עם השדה title): הטקסט שמוטמע בבניית האינדקס הופך לכותרת העמוד, שורה חדשה, ואז הפסקה. המודל לא אומן מחדש. השאלה, החיפוש, מבנה האינדקס, ה-API והממשק לא השתנו. מחיקת המפתח ובנייה מחדש מחזירות את המקור.

גרסה	Webiks, 296	נקי, 150	ציבורי, 300
המערכת המקורית	36.8 / 58.1	53.3 / 74.7	55.3 / 74.7
כותרת בטקסט (נשלח)	46.3 / 64.5	60.0 / 78.7	53.7 / 75.7
+ וקטור כותרת 0.3 (נבדק, כבוי)	52.7 / 70.9	56.0 / 77.3	54.3 / 73.0
+ דירוג LLM לפי כותרות (אופציונלי, כבוי)	60.1 / 75.3	66.7 / 84.0	60.7 / 77.3

מקום ראשון / שלושת הראשונים, % שורת הדירוג מחדש נמדדה ב-title_llm.py, שהבסיס שלו שונה מזה בעד 2 שאלות.

שלושה סטים

- Webiks: סט האימות של קוד האימון שלהם. הקובץ שימש לאימון, ולכן הטענה היא ההפרש ולא הערך המוחלט.
- נקי: 150 עמודים שאין עליהם שאלה בקובץ; שאלה לכל עמוד נכתבה מהגוף כשהכותרת מוסתרת.
- ציבורי: 300 השאלות שפרסם מתחרה ב-fork שלו.

למה וקטור הכותרת כובה

נשלח עד 04.10. על סט Webiks הוסיף 6.4 נקודות, אבל בשני הסטים העצמאיים החזיר אותן, הורע עם כל עלייה במשקל, והזיק במובהק כשהכותרת לא מתארת את הגוף. המשקל נבחר על שאלות שנכתבו מול העמוד. נשאר במנוע כאופציה כבויה.

שלב שני אופציונלי, כבוי כברירת מחדל, ומה נבדק ונפסל

ניסוי	שינוי בנקודות: מקום 3 / 1 ראשונים	למה לא
קטעים של 256 טוקנים + כותרת	-5.8 / +2.7	מול כותרת בטקסט: מחליף מקום 1 ב-3 ראשונים, אינדקס כפול, LLM מקבל חצאי פסקאות
הקשר שנכתב ב-LLM לכל פסקה	-3.7 / -0.6	מול אותה גרסה בלעדיו; עלה 3.34 דולר
ניסוח מחדש / 4 / HyDE ניסוחים	+2.4 / +3.8	במקרה הטוב; הרבה שינויים לשני הכיוונים; LLM בתוך החיפוש
סינון טקסט גנרי / 500 מועמדים	±1.5 / 0	העמוד מדורג לפי הפסקה הטובה שלו

על 296 שאלות Webiks; כל ניסוי מול אותה מערכת בלעדיו

דירוג מחדש לפי כותרות (LLM)

- החיפוש מביא 30 עמודים מועמדים; מודל שפה רואה את השאלה ואת 30 הכותרות ומחזיר את הטובים לפי הסדר.
 - ספקים דרך LLM factory: OpenAI, Azure, Ollama, vLLM, Anthropic, Gemini, או כל מודל שנרשם בכמה שורות.
 - הדלקה: TITLE_RERANK_ENABLED=true בקובץ app/.env, ספק ומודל לבחירה.
 - בכל תקלה (מפתח, זמן, תשובה לא תקינה) חוזר לסדר הרגיל.
- מחיר: כ-0.8 שנייה לשאלה, מפתח ל-LLM, ובמצב mock אין השפעה.
לכן כבוי. 19 בדיקות; 60 עוברות בסך הכול.

הצעד הבא

לבדוק את הדירוג מחדש על תנועה אמיתית ומול cross-encoder ברמת פסקה · אחזור קטן-לגדול · סט שאלות שכתבו בני אדם · לתקן במאגר עמודים שהטקסט בהם שייך לעמוד אחר (עד 271 חשודים).